

동기전동기 구동용 전압원 인버터의 인공 신경망 기반 비선형성 추정

Neural Network-based Nonlinearity Estimation of Voltage Source Inverter for Synchronous Machine Drives

○정영호¹, 최경환^{1*}

¹⁾ 광주과학기술원 기계공학부 (TEL: 062-715-2413; E-mail: bbang988@gm.gist.ac.kr, khchoi@gist.ac.kr)

Abstract This paper investigates the concept of using a neural network (NN)-based approach for the nonlinearity estimation of voltage source inverter (VSI) in synchronous machine (SM) drives. The proposed scheme utilizes an NN with one hidden layer to model the VSI nonlinearity, accompanied by an adaptive law that ensures stability and bounded weights during the NN's update process. Assuming known stator flux linkages, the study primarily evaluates the feasibility of applying NN for this estimation. Simulation results from a 35 kW SM drive indicate that the proposed estimator successfully tracks the actual value of the VSI nonlinearity, demonstrating its efficacy.

Keywords neural network (NN), online estimation, voltage source inverter (VSI), synchronous machine (SM), system identification

1. 서론

전압원 인버터는 동기전동기 구동에 매우 중요하며, DC 전원을 AC 전원으로 크기와 주파수를 조정하여 변환할 수 있다. 이러한 변환 가능성은 다양한 분야에서 정밀한 제어를 위한 기본 요소이다. 그러나 이상적이지 않은 실제 전압원 인버터에서 데드 타임, 스위칭 지연 및 전력 소자의 전압 강하로 인해 비선형성이 발생하여 제어 성능과 시스템 안정성에 영향을 미쳐 문제를 발생시킨다. 이러한 비선형성은 실제 지령 전압과 인버터를 통해 출력된 전압에 차이가 생기게 만들기에, 비선형성을 정확하게 추정하고 보상해주는 것은 매우 중요하다.

인버터 비선형성은 일반적으로 진폭에 따라 고정자 전류의 부호 함수를 사용하여 abc 좌표축에서 모델링된다. 기존의 인버터 비선형성 추정 방법으로는 재귀적 최소 제곱[1], 전류 주입[2]을 사용한 방법이 제안되었다. 하지만 비선형성은 포화 상태의 연속 함수로 표현하는 것이 더 정확하며 이를 일반화한 모델이 필요하다.

본 논문에서는 인공 신경망을 통해 추정된 함수로 인버터 비선형성을 추정하는 방법을 제안한다. 쇄교 자속 맵을 통해 실제 쇄교 자속을 안다고 가정하고, 이를 이용한 각종 행렬의 업데이트 법칙을 설계하여 인버터 비선형성을 추정한다. 35 kW 동기전동기 시뮬레이션의 결과를 통해 제안한 추정기가 실제 비선형성을 정확하게 추정함을 효과적으로 입증한다.

2. 이론적 배경

dq 좌표축에서 동기전동기의 전기적 동역학은 다음과 같이 모델링된다.

$$\begin{aligned}\dot{\lambda}_{dq}(t) &= \mathbf{v}_{dq}(t) - \omega_r \mathbf{J} \lambda_{dq}(t) - R_s i_{dq}(t), \\ T_e(t) &= 1.5P \mathbf{i}_{dq}^T \mathbf{J} \lambda_{dq}.\end{aligned}\quad (1)$$

여기서 $\mathbf{z}_{dq} = [z_d \ z_q]^T$, $z = \lambda, v, i$ 이고 λ 는 고정자 쇄교 자속, v 는 고정자 전압, i 는 고정자 전류, ω_r 은 전기 각속도, T_e 는 출력 토크, \mathbf{R}_s 는 고정자 저항, P 는 극쌍수, 그리고 $\mathbf{J} = \begin{bmatrix} 0 & -1 \\ 1 & 0 \end{bmatrix}$ 인 변환 행렬이다.

데드 타임, 스위칭 지연, 그리고 전력 소자에 의한 전압 강하와 같은 비선형성은 목표 전압 \mathbf{v}_z^* 과 실제 인버터를 통해 출력된 전압 \mathbf{v}_z 이 차이 나게 한다 (즉, $\Delta_z = \mathbf{v}_z^* - \mathbf{v}_z$, z 는 dq 또는 abc 좌표축이다). 이러한 전압 차이의 abc 좌표축에서의 모델이 [3]에서 수식으로 표현되었다. 이와 같이 표현한 전압 차이는 인버터의 정확한 파라미터를 알지 못해 정확하지 않다. 따라서 비선형성을 실시간으로 추정하여 더 정확하게 보상하는 방법이 필요하다.

3. 인공 신경망 기반 추정 기법

동기전동기의 전기적 동역학 수식 (1)은 다음 상태 공간 방정식으로 표현할 수 있다.

$$\begin{aligned}\dot{x}(t) &= A(\omega_r)x(t) + Bu(t) + \Delta_{dq}(t), \\ y(t) &= Cx(t).\end{aligned}\quad (2)$$

여기서 $x = \lambda_{dq}$, $u = [(v_{dq}^*)^T \quad i_{dq}^T]^T$, $y = \lambda_{dq}$, $A = -\omega_r J$, $B = [I_2 \quad -R_s I_2]$, $C = I_2$, Δ_{dq} 는 인버터 비선형성이다. 이 수식을 안정하게 하는 새로운 행렬 \bar{A} 와 그에 대응하는 새로운 비선형성 ϵ_{dq} 로 표현하면 다음과 같은 수식이 성립한다.

$$\begin{aligned}\dot{x}(t) &= \bar{A}x(t) + Bu(t) + \epsilon_{dq}(t), \\ y(t) &= Cx(t), \\ \epsilon_{dq}(t) &= \Delta_{dq}(t) + (A(\omega_r) - \bar{A})x(t).\end{aligned}\quad (3)$$

새로운 비선형성 ϵ_{dq} 은 일정 범위 내의 가중 행렬과 활성 함수를 통해 정의한다.

$$\epsilon_{dq}(t) = W\sigma(V\bar{x}(t)), \quad (4)$$

$$\|W\|_F \leq W_M, \|V\|_F \leq V_M. \quad (5)$$

여기서 W , V 는 가중 행렬, \bar{x} 은 인공 신경망 입력 벡터, 그리고 σ 는 활성 함수이다. 또한, 수식 (3)을 추정하기 위한 수식은 다음과 같다.

$$\begin{aligned}\hat{x}(t) &= \bar{A}\hat{x}(t) + Bu(t) + \hat{\epsilon}_{dq}(t), \\ \hat{y}(t) &= C\hat{x}(t), \\ \hat{\epsilon}(t) &= \hat{W}\sigma(\hat{V}\hat{x}(t)).\end{aligned}\quad (6)$$

$e(t) = x(t) - \hat{x}(t)$ 으로 정의하고 수식 (3)과 수식 (6)을 통해 다음과 같은 수식이 성립한다.

$$\dot{e}(t) = \bar{A}e(t) + \epsilon_{dq}(t) - \hat{\epsilon}_{dq}(t). \quad (7)$$

위 수식에서 $\epsilon_{dq}(t) - \hat{\epsilon}_{dq}(t)$ 부분이 매우 작은 값이라면 오차 e 는 지수적으로 수렴한다. 비선형성 오차를 줄이기 위해서는 가중 행렬 적응 법칙이 잘 설계되어야 한다.

가중 행렬의 적응 법칙은 역전파(backpropagation) 방식을 사용하여 다음과 같이 설계한다.

$$\begin{aligned}\dot{W} &= -\eta \frac{\partial G}{\partial W} - \rho \|e\| \hat{W}, \\ \dot{V} &= -\eta \frac{\partial G}{\partial V} - \rho \|e\| \hat{V}.\end{aligned}\quad (8)$$

여기서 $G = \frac{1}{2}e^T e$ 인 오차 감소 목적 함수, η 는 학습률, ρ 는 감쇠 계수이다. 위와 같은 적응 법칙을 통해 오차 e 를 감소시킬 수 있다.

4. 시뮬레이션

시뮬레이션 파라미터는 다음과 같이 설정한다.

$$\eta = 10, \rho = 2 \times 10^{-6}, \bar{A} = \begin{bmatrix} -10^4 & -400 \\ 400 & -10^4 \end{bmatrix}. \quad (9)$$

본 시뮬레이션에서는 0.01 초 시점에서 0.02 초 동안 출력 토크를 0에서 180Nm로 증가하도록 구동하였다. 그림 1에서는 실제 쇄교 자속 값과 비선형성을 보상한 상태인 수식 (6)을 기반으로 추정한 쇄교 자속, 그리고 비선형성을 보상하지 않은 상태에서 추정한 쇄교 자속을 나타낸다. 그림 2에서는 실제 비선형성, 인공 신경망 기반 추정 비선형성, 그리고 수식 기반 비선형성[3]을 나타낸다.

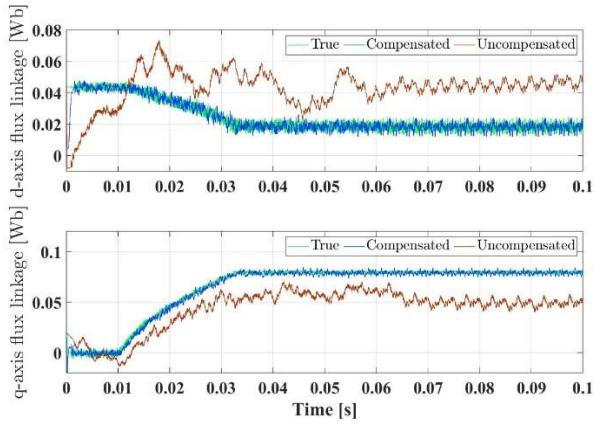


그림 1. 고정자 쇄교 자속 추정

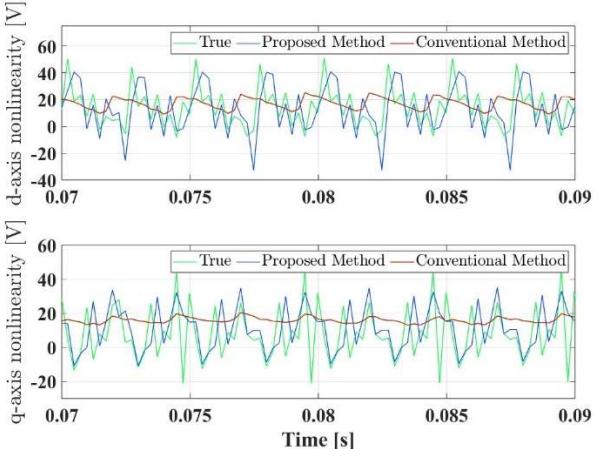


그림 2. 전압원 인버터 비선형성 추정

5. 결론

본 논문에서는 인공 신경망 기반의 전압원 인버터 비선형성 추정 방안에 대한 방안을 제시하였다. 제안 방안을 통해 부정확할 수 있는 파라미터를 사용한 수식 기반의 방안 대신 실시간으로 업데이트하는 인공 신경망을 통해 더 정확하게 비선형성을 추정할 수 있다. 잘 설계된 가중 행렬의 적응 법칙을 통해 실제 쇄교 자속과 추정하는 쇄교 자속의 오차를 줄이도록 하는 인버터 비선형성을 추정하였다. 시뮬레이션을 통해 제안 방안의 효과를 입증하였다.

참고문헌

- [1] C. Lian, F. Xiao, J. Liu, and S. Gao, "Parameter and VSI nonlinearity hybrid estimation for PMSM drives based on recursive least square," *IEEE Transactions on Transportation Electrification*, 2022.
- [2] K. Yu and Z. Wang, "An online compensation method of VSI nonlinearity for dual three-phase PMSM drives using current injection," *IEEE Transactions on Industrial Electronics*, vol. 37, no. 4, pp. 3769-3774, 2021.
- [3] H.-W. Kim, M.-J. Youn, K.-Y. Cho, and H.-S. Kim, "Nonlinearity estimation and compensation of PWM VSI for PMSM under resistance and flux linkage uncertainty," *IEEE Transactions on Control Systems Technology*, vol. 14, no. 4, pp. 589-601, 2006.